课题四：锂离子电池退化分析与剩余寿命预测

一、背景介绍

锂离子电池在长期充放电循环中，由于内部副反应的累积，其最大可用容量会逐渐衰减，内阻会逐渐增大。本课题的数据集来源于美国马里兰大学 CALCE 中心的公开电池数据集。数据集采用 4 块同型号的钴酸锂电池（如图 1 所示），电池具体信息如图 2 所示。一般来说，锂离子电池寿命的标准是容量减少 20%，CS2 的标称容量为 1100mAh，故而我们定义失效阈值为 1100mAh×80%=880mAh =0.88Ah（即 **capacity=0.88**）。

Prismatic Cells

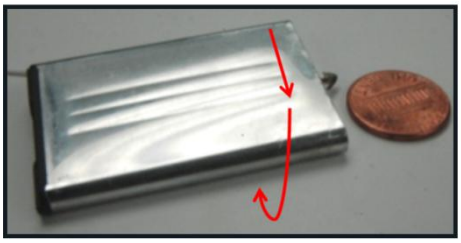

CS2 Battery

图 1 CS2 电池示意图

Battery (Parameters)	Specifications (Value)
Capacity Rating	1100 mAh
Cell Chemistry	LiCoO2 cathode, EDS results also showed trace elements of Manganese
Weight (w/o safety circuit)	21.1 g
Dimensions	5.4 x 33.6 x 50.6 mm
Special Notes	Jellyroll configuration wrapped around the "length" axis, indicated by red arrows below

图 2 CS2 电池具体信息

电池编号分别为 CS2_35，CS2_36，CS2_37，CS2_38。数据字段包括 cycle、capacity、SoH、resistance、CCCT 和 CVCT，具体信息如下：

- cycle（循环次数）：电池经历的充放电周期数。
- capacity（容量）：电池在当前循环下能释放的实际电量。
- SoH（State of Health，健康状态）：反映电池寿命和健康状况的指标（通常由当前容量与初始额定容量之比得出）。

- resistance（内阻）：电池内部的电阻，内阻增加通常表示老化。
- CCCT（Constant Current Charge Time，恒流充电时间）：充电阶段中，以恒定电流进行充电所花费的时间。
- CVCT（Constant Voltage Charge Time，恒压充电时间）：充电阶段中，以恒定电压进行充电所花费的时间。

二、课题内容

本课题要求对上述 4 个电池的循环老化数据进行分析与建模，主要分为两个部分：基于维纳过程的退化分析和基于人工智能的剩余寿命预测；需完成数据预处理、模型建立、参数估计、寿命预测及对比分析等任务。

2.1 数据预处理

在建模之前，需要对原始数据进行清洗和预处理，以确保数据质量。具体步骤包括：

1. 缺失值处理：检查各字段是否存在缺失值（0 或空值），对于少量缺失可采用插值处理，需要说明选择插值方法的依据。

2. 异常值检查与处理：检测是否存在异常值，对于明显的测量异常（如容量突然跳变），需结合前后循环进行修正或剔除。

3. 数据平滑：由于测量存在误差，退化曲线可能出现局部波动。可选用移动平均或滤波方法对退化指标进行平滑，但需注意保留退化趋势。

2.2 基于随机效应 Wiener 过程的退化数据分析和寿命评估

1. 基于随机效应 Wiener 过程的容量退化建模与参数估计

(1) 使用考虑随机效应的 Wiener 过程对四个电池的 capacity 退化数据进行建模。模型假设如下：

- 每个电池的退化过程可表示为 $X_i(t) = X_i(0) + \mu_i t + \sigma W(t)$
- 漂移系数 μ_i 在不同电池间服从正态分布：$\mu_i \sim N(\mu_0, \sigma_\mu^2)$

(2) 采用 MLE 方法估计模型中的参数，参数为平均漂移 μ_0、漂移间标准差 σ_μ^2、扩散系数 σ。

(3) 绘制似然函数在参数估计过程中的变化曲面（三维图），以两个关键参数为自变量，以似然值为因变量，结合图形说明 MLE 的基本原理。

(4) 绘制退化增量的直方图及其拟合的概率密度函数（PDF）曲线。

2. 个体漂移推断与退化分析

(1) 利用估计的模型参数，通过经验贝叶斯方法计算每个电池的随机漂移后验估计值 $\hat{\mu}_i$，并分析四个电池间的退化速率差异。

(2) 绘制每个电池的实际退化曲线与模型拟合曲线，评估模型对个体退化轨迹的拟合效果。

3. 首达时分布与寿命推断

(1) 以 capacity=0.88 作为失效阈值。基于随机效应 Wiener 过程的首达时分布理论，推导寿命的 CDP、PDF 和可靠度函数 R(t)。

(2) 绘制 CDF、PDF 和 R(t)的曲线。

(3) 计算随机效应 Wiener 过程下的中位寿命。

2.3 基于人工智能的剩余寿命预测

1. 基于循环神经网络的时序预测

(1) 使用 LSTM 网络，确定合适的时间滑窗尺寸，以历史 capacity 序列（或结合 resistance、CCCT、CVCT 等多变量）为输入，预测未来 capacity 或直接预测剩余寿命。

(2) 评估预测精度，计算相应指标（RMSE、MAE 等）。

2. 基于特征工程的机器学习回归

(1) 从原始数据中提取特征，比如当前循环的 capacity、resistance、CCCT、CVCT，以及这些量的滑动统计特征（均值、方差、梯度等）。

(2) 将剩余寿命（即到达失效阈值所需的剩余循环数）作为目标变量，训练回归模型（如 XGBoost、随机森林、支持向量回归）。

(3) 分析特征重要性，找出对退化影响最大的关键特征。

3. 基于多任务学习的电池多性能指标预测（选做）

(1) 以滑动窗口内的多变量序列（capacity、resistance、CCCT、CVCT）为输入，设计共享底层（LSTM 或全连接层）加上多个任务特定输出层的网络结构，同时预测未来多个时间步的 capacity、resistance、CCCT 和 CVCT。

(2) 采用加权联合损失训练模型，各任务损失可使用 MSE 或 MAE，权重根据任务重要性或量级调整。

(3) 采用与第 1 节相同的数据划分，训练多任务模型并与单任务 LSTM 模型（仅预测容量）对比，记录容量预测的 RMSE 和 MAE。

(4) 绘制多任务模型与单任务模型的容量预测对比曲线，对比多任务学习与单任务学习。